



PRESENTATION

Study of the TRL library and its applications

Study of the TRL library and its applications

1

- Tổng quan về RL
- Khái quát TRL library
- Cài đặt thư viện và các phụ thuộc cần thiết

2

- Khám phá các chức năng của TRL với các mô hình Hugging Face Transformer
- Triển khai các thuật toán RL như PPO, DDO
- Chọn tác vụ đơn giản, áp dụng TRL để tinh chỉnh các mô hình biến đổi cơ sở

3

- Tiến hành các thí nghiệm chuyên sâu hơn với các nhiệm vụ phức tạp hơn
- Đánh giá hiệu suất
- Ưu điểm & nhược điểm của TRL
- Báo cáo



Week 1

1. Tổng quan về RL (Reinforcement Learning):

- RL là một nhánh của machine learning, nơi một tác nhân (agent) học cách đưa ra quyết định bằng cách tương tác với môi trường để tối đa hóa phần thưởng (reward).
- Các khái niệm chính: trạng thái (state), hành động (action), chính sách (policy), giá trị (value), và phần thưởng.
- Tài liệu tham khảo: Bạn có thể tìm sách như "Reinforcement Learning: An Introduction" của Sutton và Barto (bản PDF thường có trên web học thuật).

2. Khái quát TRL:

- TRL là thư viện của Hugging Face tích hợp RL với mô hình transformer (như GPT, BERT) để tinh chỉnh mô hình ngôn ngữ.
- Các phương pháp chính: Supervised Fine-Tuning (SFT), Proximal Policy Optimization (PPO), Direct Preference Optimization (DPO).

3. Cài đặt thư viện:

```
pip install trl transformers accelerate datasets
```

```
datasets>=1.17.0
```

```
torch>=1.4.0
```

```
tqdm
```

```
transformers
```

```
accelerate
```

```
peft>=0.3.0
```

```
tyro>=0.5.7
```

- **Mục tiêu:** Thực hành với các phương pháp RL trong TRL (PPO, DDO) và áp dụng cho mô hình transformer.

PPO(Proximal policy optimization):

- Một thuật toán học tăng cường chính sách phổ biến.
- được dùng để fine-tune LLM bằng phản hồi từ mô hình chấm điểm (Reward Model).
- Quy trình được gọi là RLHF (Reinforcement Learning from Human Feedback).

Cách hoạt động:

- Dùng LLM sinh ra phản hồi (text).
- Đánh giá phản hồi đó bằng mô hình Reward Model (có thể được huấn luyện từ dữ liệu con người đánh giá).
- Dùng điểm số reward này để cập nhật LLM thông qua thuật toán PPO.

DPO(Direct Preference Optimization):

- Là phương pháp học có giám sát từ dữ liệu so sánh: (prompt, phản hồi tốt, phản hồi kém).
- Không cần reward model.
- Ổn định, dễ huấn luyện và đang được áp dụng nhiều.

Cách hoạt động:

- Có cặp dữ liệu (prompt, response_chosen, response_rejected) — phản hồi được yêu thích và phản hồi bị từ chối.
- Huấn luyện mô hình để xác suất sinh ra response_chosen cao hơn response_rejected.
- Không cần reward model, không cần pipeline RL phức tạp.

Simple task: Text generation

- Mô hình cơ sở: gpt2
- Dữ liệu: prompt tổng hợp + phản hồi thích và không thích
- Nhiệm vụ: Sinh văn bản phù hợp/hữu ích từ một prompt

Thực nghiệm

- Huấn luyện mô hình GPT-2 bằng PPO trên tập dữ liệu prompt + phản hồi.
- PPO, dùng hàm reward đơn giản (ưu tiên phản hồi dài, rõ ràng).

Thực nghiệm

- Mô hình khởi đầu: GPT-2 đã SFT
- Dữ liệu: 100 mẫu prompt + completion
- Reward function: so sánh với reference theo các mức độ tương đồng
- Kết quả:
- Trung bình reward tăng qua từng epoch
- Model sinh đầu ra tốt hơn, ít lặp lại prompt

Thực nghiệm

```
[Epoch 1] Query: What is the chemical symbol for water?  
Reference: H2O  
Response: What is the chemical symbol for water?  
Answer: H2O2  
Water is the main component in natural gas, which is the main fuel for cars and other vehicles.  
Answer  
Reward: 2.50  
  
[Epoch 1] Query: Who developed the theory of relativity?  
Reference: Albert Einstein  
Response: Who developed the theory of relativity?  
Answer: Albert Einstein  
Answer: General Relativity  
Answer: 2  
Answer: 1  
Answer: 2  
Answer: 3  
Answer:  
Reward: 2.50  
  
[Epoch 1] Query: What year did World War II end?  
Reference: 1945  
Response: What year did World War II end?  
Answer: 1945  
Answer: 1945  
Answer: 1945  
Answer: 1945  
Answer: 1945  
Answer: 1945  
Answer: 1945  
Answer:  
Reward: 2.50  
  
[Epoch 1] Query: What is the capital of Canada?  
Reference: Ottawa  
Response: What is the capital of Canada?  
Answer: Ottawa  
Capital: Ottawa  
Countries: Ottawa  
Source: Ottawa: Canada  
How many provinces are there?  
Answer: Seven  
Reward: 2.50
```


Ưu điểm của TRL:

1. Tối ưu trực tiếp theo mục tiêu cuối (goal-aligned output)
 - Có thể thiết kế reward theo độ chính xác, độ dài, toxicity, factuality,...
 - DPO: không cần reward, chỉ cần preference pairs
2. Điều chỉnh hành vi mô hình mà không cần nhãn rõ ràng
 - Khác với SFT cần label cụ thể
- 3- Thư viện TRL hỗ trợ rất tốt:
 - Tích hợp sẵn với HuggingFace (transformers, datasets)
 - Có PPOTrainer, DPOTrainer, RewardTrainer...
- 4- Mô hình học từ phản hồi của con người hoặc hệ thống dễ dàng
 - Hướng tới RLHF – phương pháp cốt lõi để fine-tune ChatGPT, Claude,...

Nhược điểm:

1- Yêu cầu tài nguyên lớn

- PPO cần rollout nhiều lần, DPO cần dữ liệu preference
- Huấn luyện chậm hơn SFT nhiều

2- Khó thiết kế reward tốt

- Nếu reward sai → mô hình học sai

3- Cần có base model và reference model

- Gây tốn RAM/VRAM (dễ out-of-memory với GPT-2)



THANK
YOU.